Оглавление

Цель проекта 2
Исходные данные 2
Модель данных 2
Добавление аэропортов в модель данных 3
Загрузка аэропортов в слой ods 3
Загрузка аэропортов в слой dds. 3
Добавление погоды в аэропортах в модель данных 4
Загрузка погоды в слой ods 4
Загрузка погоды в слой stg. 4
Загрузка погоды в слой dds. 5
Добавление авиаперевозок в модель данных 6
Загрузка авиаперевозок в слой ods 6
Загрузка авиаперевозок в слой stg. 6
Загрузка авиаперевозок в слой dds. 7
Логическая модель слоя dds. 8
Разработка витрины данных для анализа авиаперевозок 10
Создание BI в DataLens 11

Цель проекта

Целью данной проектной работы является создание витрины данных для анализа перелетов на домашних рейсах США с последующим построением отчетов на основе подготовленных данных:

1. отчет по количеству отмененных рейсов в разрезе времени, причин отмены и атрибутов аэропорта
2. отчет по отменам рейсов из-за погодных условий в разрезе времени, аэропорта, погодных параметров

Исходные данные

Аэропорты, которые мы будем анализировать: Anchorage, AK (ANC), Fairbanks, AK (FAI), Montgomery, AL (MGM), Dothan, AL (DHN). В скобках приведен IATA код аэропорта.

Мы добавили исходные данные с погодными условиями в формате csv, полученные с сайта http://rp5.ru в бакет S3 (s3://gsbdwhdata/dev_team_1/CCCC_weather.csv, где CCCC - ICAO код аэропорта).

В бакете s3://gsbdwhdata/flights/ хранятся данные авиаперевозок в соответствующих файлах (T_ONTIME_REPORTING-YYYY-MM.csv, где YYYY – год, MM - месяц).

В этот же бакет мы добавили справочник аэропортов, в котором приведены коды аэропортов (Ident – ICAO code, iata_code - IATA code), которые мы будем использовать для связывания таблиц авиаперевозок и погоды.

Модель данных

- **ODS (Operational Data Store)** — слой оперативного хранения данных.
- **STG (Staging)** — слой подготовки данных.
- **DDS (Detail Data Store)** — основной слой Хранилища, детальные данные.
- **DM (Data Mart)** — слой пользовательских витрин.

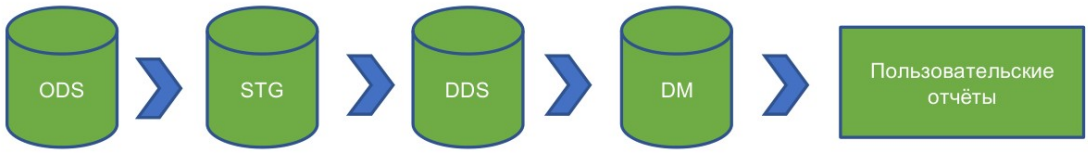

Добавление аэропортов в модель данных

В целевой витрине нужны сведения об аэропортах.

Загрузка аэропортов в слой ods

Производится вручную.

Запускается DAG с id *dev_team_1_load_airports_to_ods*. Программа ожидает наличия файла с названием s3://dev_team_1/flights/airports.csv. При его наличии читает и создает заново таблицу ods.airport с полями:

Поле	**Название**
icao_code	id аэропорта ICAO
iata_code	id аэропорта IATA
type	тип аэропорта
name	название аэропорта
elevation_ft	высота над уровнем моря
iso_country	код страны
iso_region	код региона
region_name	название региона
city_name	название города
city_code	код города
time_zone	часовой пояс

Загрузка аэропортов в слой dds.

Поля таблицы ods.airport совпадают с полями таблицы dds.airport.

На этом шаге вручную запускается DAG с id *dev_team_1_load_airports_to_dds*, который производит дедупликацию и загрузку из таблицы ods.aiport в таблицу dds.airport.

Добавление погоды в аэропортах в модель данных

В целевой витрине нужны сведения о погоде.

Давайте выстроим процесс загрузки информации о погодных условиях в наше хранилище данных.

Загрузка погоды в слой ods

Производится вручную. Внимание: перед запуском этих шагов надо заполнить параметр *dev_team_1_airport_weather*, указав в нём ICAO коды аэропортов через пробел. Например, PANC PAFA.

Мы будем использовать следующие коды аэропортов: PANC (Anchorage), PAFA (Fairbanks), KDHN (Dothan), KMGM (Montgomery).

Запускается DAG с id dev_team_1_load_weather_to_ods, который ожидает наличия файлов с названием s3://gsbdwhdata/dev_team_1/CCCC_weather.csv, где CCCC - ICAO код аэропорта, удаляет лишние лидирующие строки (заголовок), выделяет следующие поля:

- ICAO код аэропорта,
- время измерения,
- температура,
- скорость ветра,
- максимальная скорость порыва ветра между измерениями,
- текстовое описание погоды.

и создает заново таблицу ods.weather с полями:

Поле	**Название**
icao_code	ICAO код аэропорта
local_time	дата и время измерения
temperature	температура
w_speed	скорость ветра
max_gws	максимальная скорость порыва ветра между измерениями
w_phenomena	текстовое описание погоды
processed_dttm	дата и время загрузки

Загрузка погоды в слой stg.

Поля таблицы stg.weather совпадают с полями таблицы ods.weather.

На этом шаге автоматически каждые 5 минут запускается DAG с id *dev_team_1_load_weather_to_stg*, который производит дедупликацию и инкрементальную загрузку (только данные, измененные между запусками, для чего в запросе используются системные переменные Airflow) из таблицы ods.weather в таблицу stg.weather.

Загрузка погоды в слой dds.

При заполнении таблицы dds.weather используем следующие преобразования:

Поле	**Название**	**Правила заполнения**
airport_rk	ID аэропорта IATA	Подставляется iata_code из dds.airports (справочник аэропортов). join по icao_code
w_speed	Скорость ветра	Значение из поля w_speed
max_gws	Макс. порывы ветра	Значение из поля max_gws
t_deg	Температура	Значение из поля temperature
w_phenomena	Текстовое описание погоды	Значение поля w_phenomena
valid_from_dttm	Начало периода	Значение из поля local_time
valid_to_dttm	Окончание периода	Следующее известное время сбора данных для этого аэропорта или дата в будущем (5999-01-01)
processed_dttm	Время загрузки	

Используется следующий метод загрузки: удаление записей из dds.weather, в которых аэропорт и начало периода совпадают соответствующими значениями из stg.weather, измененными между запусками, а затем вставка в dds.weather всех измененных между запусками записей из stg.weather.

Добавление авиаперевозок в модель данных

В целевой витрине нужны сведения об авиаперевозках.

Загрузка авиаперевозок в слой ods

Производится вручную для каждого месяца. Внимание: перед запуском надо заполнить параметр *dev_team_1_year_month*, указав в нём YYYY-MM, где YYYY – год, MM – месяц. В нашем случае используем диапазон январь-июнь 2024 года.

Запускается DAG с id *dev_team_1_load_flights_to_ods*. Программа ожидает наличия файла с названием s3://gsbdwhdata/flights/T_ONTIME_REPORTING-YYYY-MM.csv, где YYYY – год, MM - месяц. При его наличии читает и создает заново таблицу ods.flights с полями:

Поле	**Название**
Year	
Month	
flight_dt	дата в формате YYYY-MM-dd
carrier_code	код перевозчика
tail_num	номер самолета
carrier_flight_number	номер рейса
origin_code	аэропорт вылета
origin_city_name	город аэропорта вылета
dest_code	аэропорт прилёта
dest_city_name	город аэропорта прилёта
scheduled_dep_tm	запланированное время отправления без даты в формате HH:mm
actual_dep_tm	фактическое время прибытия
arr_delay_min	задержка прибытия в минутах
arr_delay_group_num	номер группы опоздания
cancelled_flg	флаг отмены рейса
cancellation_code	код причины отмены
filghts_cnt	количество рейсов в одном маршруте
distance	расстояние
distance_group_num	группа расстояния
carrier_delay_min	задержка в минутах по вине перевозчика
weather_delay_min	задержка из-за погоды
nas_delay_min	задержка из-за NAS(National aviation services)
security_delay_min	задержка из-за проверки безопасности
late_aircraft_min	задержка из-за позднего прибытия самолета
processed_dttm	время загрузки

Загрузка авиаперевозок в слой stg.

Поля таблицы stg. flights совпадают с полями таблицы ods. flights.

На этом шаге автоматически каждые 5 минут запускается DAG с id *dev_team_1_load_flights_to_stg*, который производит дедупликацию и инкрементальную загрузку данных, измененных между запусками, из таблицы ods.flights в таблицу stg.flights.

Загрузка авиаперевозок в слой dds.

На этом шаге автоматически каждые 5 минут запускается DAG с id *dev_team_1_load_flights_to_dds*, который производит инкрементальную загрузку данных, измененных между запусками, из таблицы stg.flights в две таблицы в слое DDS:

1. Успешные рейсы

2. Отмененные рейсы

Состав таблицы выполненных рейсов:

Поле	**Название**	**Участие в ключе**
carrier_flight_num	Номер рейса перевозчика	Да
flight_dttm_local	Локальное время и дата вылета	Да
origin_airport_dk	Код аэропорта отправления	Да
dest_airport_dk	Код аэропорта назначения	
carrier_code	Код перевозчика	Да
tail_num	Бортовой номер самолета	
distance_m	Дальность полета (мили)	
dep_delay_min	Задержка вылета (минуты)	
delay_reasons_code	Причины задержки (Расчетное поле)	
processed_dttm	Время вставки записи	

Состав таблицы отменённых рейсов:

Поле	**Название**	**Участие в ключе**
carrier_flight_num	Номер рейса перевозчика	Да
sched_dttm_local	Локальное время и дата вылета	Да
origin_airport_dk	Код аэропорта отправления	Да
dest_airport_dk	Код аэропорта назначения	
carrier_code	Код перевозчика	
cancellation_code	Код причины отмены рейса	
processed_dttm	Время вставки записи	

Логическая модель слоя dds.

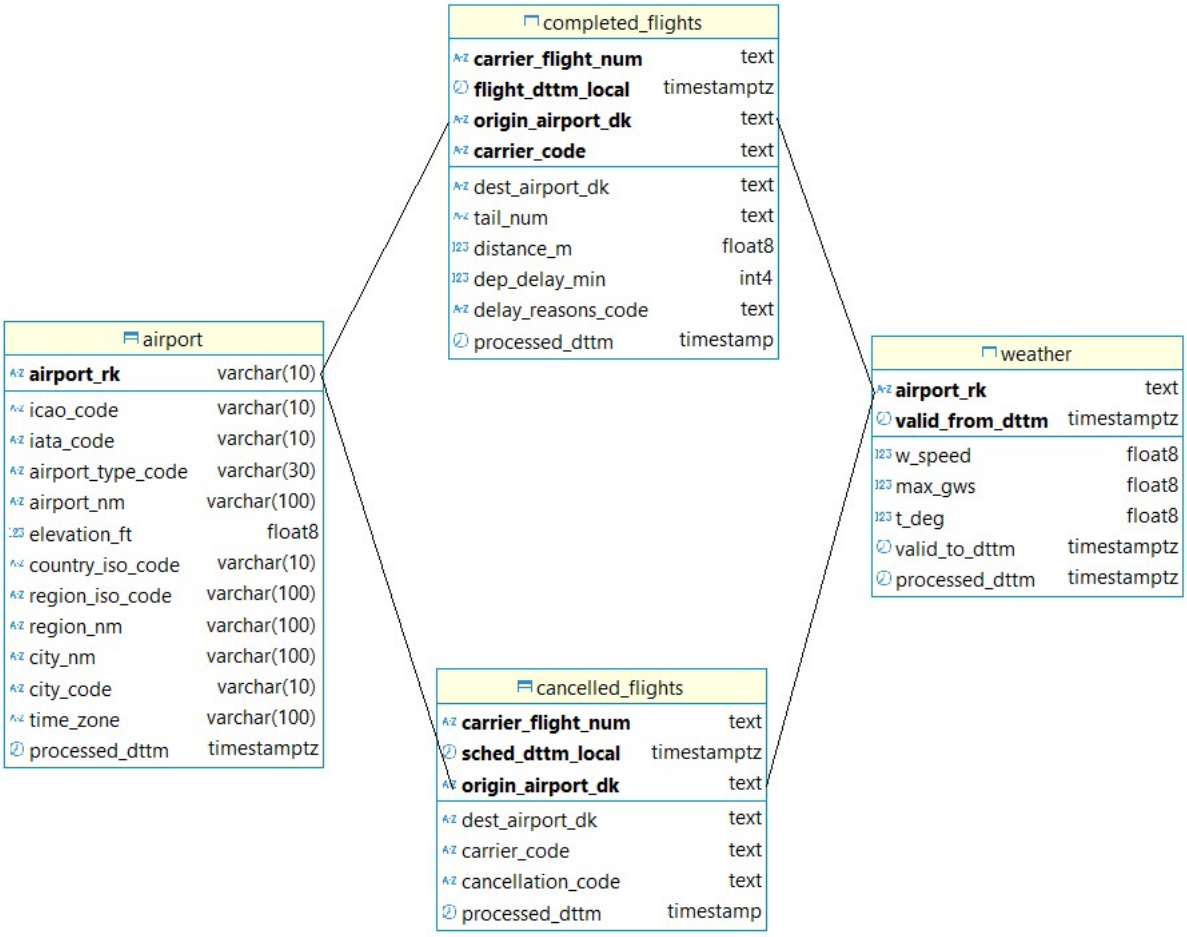

Все DAGи отработали успешно:

Airflow DAGs Datasets Browse Admin 12:41 UTC ПА

All 9 | Active 0 | Paused 9 | Running 0 | Failed 0 | × dev_team_1 | Search DAGs | Auto-refresh

DAG	Owner	Runs	Schedule	Last Run	Next Run	Recent Tasks	Actions	Links
dev_team_1_load_airports_to_dds (dev_team_1)	airflow	4	None	2025-06-03, 14:02:17		1		
dev_team_1_load_airports_to_ods (dev_team_1)	airflow	1	None	2025-06-05, 11:09:17		3		
dev_team_1_load_flights_to_dds (dev_team_1)	airflow	19	0:05:00	2025-06-12, 09:43:50	2025-06-17, 12:30:00	1		
dev_team_1_load_flights_to_ods (dev_team_1)	airflow	7	None	2025-06-12, 09:43:01		3		
dev_team_1_load_flight_to_stg (dev_team_1)	airflow	13	0:05:00	2025-06-12, 09:43:30	2025-06-17, 12:35:00	1		
dev_team_1_load_weather_to_dds (dev_team_1)	airflow	18	0:05:00	2025-06-09, 11:48:28	2025-06-17, 12:30:00	1		
dev_team_1_load_weather_to_ods (dev_team_1)	airflow	1	None	2025-06-04, 13:51:49		2		
dev_team_1_load_weather_to_stg (dev_team_1)	airflow	7	0:05:00	2025-06-04, 13:52:09	2025-06-17, 12:35:00	1		
dev_team_1_refresh_dm (dev_team_1)	airflow	5	0:05:00	2025-06-12, 09:45:08	2025-06-17, 12:30:00	1		

« ‹ 1 › »

Showing 1-9 of 9 DAGs

Разработка витрины данных для анализа авиаперевозок

Создаем витрины данных (посредством создания MATERIALIZED VIEW в слое dm), которые помогут решить выбранные нами задачи.

Витрина dm.mv_cancelled_base:

Поле	Название	Правила заполнения
airport_rk	ID аэропорта вылета	origin_airport
reason	причина отмены	CASE cancellation_code WHEN 'A' THEN 'по решению перевозчика' WHEN 'B' THEN 'по погодным условиям' ELSE 'по техническим причинам'
sched_dttm	Дата вылета по расписанию	date(sched_dttm_local)
cancellation_cnt		Вычисляемое поле
region_code	Название штата	region_nm

airport_rk	reason	sched_dttm	cancellation_cnt	region_code
ATL	по погодным условиям	2024-03-23	3	Georgia
CRW	по погодным условиям	2024-01-19	2	West Virginia
SNA	по решению перевозчика	2024-06-22	2	California
DAL	по погодным условиям	2024-03-15	7	Texas
OTH	по погодным условиям	2024-02-03	1	Oregon
SHV	по погодным условиям	2024-05-27	1	Louisiana
LWS	по погодным условиям	2024-01-25	1	Idaho
MOT	по погодным условиям	2024-03-02	2	North Dakota
BOI	по погодным условиям	2024-01-14	2	Idaho
DCA	по решению перевозчика	2024-06-19	1	District of Columbia
RSW	по решению перевозчика	2024-02-04	1	Florida
MCO	по решению перевозчика	2024-03-02	2	Florida
AUS	по погодным условиям	2024-05-06	1	Texas

Витрина dm.mv_cancelled_weather_report:

Поле	Название	Правила заполнения
airport_rk	ID аэропорта вылета	
sched_dttm	Дата вылета по расписанию	
w_phenomena	Текстовое описание погоды	
rain_flg	Дождь	w_phenomena включает ‘rain’
snow_flg	Снег	w_phenomena включает ‘snow’
thunderstorm_flg	Гроза	w_phenomena включает ‘thunderstorm'
fog_mist_flg	Туман/Мгла	w_phenomena включает 'fog' или 'mist'
drizzle_flg	Морось	w_phenomena включает 'drizzle'
freezing_flg	Холодно	t_deg < 0
avg_w_speed	Средняя скорость ветра	Значение из поля w_speed
max_gws	Макс. порывы ветра	Значение из поля max_gws
avg_t_deg	Температура	Значение из поля t_deg
airport_rk	ID аэропорта вылета	
city_nm	Название города	
region_nm	Название штата	

country_iso_code	Код страны	
time_zone	Часовой пояс	
cancellation_cnt	Количество отмененных рейсов	Вычисляемое поле
delay_min_avg	Средняя задержка Вылета	Вычисляемое поле
valid_from_dttm	Начало периода	
valid_to_dttm	Окончание периода	
processed_dttm	Время загрузки	

airport_rk	sched_dt	cancellation_cnt	avg_w_speed	avg_t_deg	w_phenomena	rain_flg	snow_flg	thunderstorm_flg	fog_mist_flg	drizzle_flg	freezing_flg
ANC	2024-01-01	3	3	-6	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-02	2	3	-7	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-03	2	6	-2	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-05	2	0	-7	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-10	1	2	-7	Mist	[ ]	[ ]	[ ]	[v]	[ ]	[v]
ANC	2024-01-11	1	3	-6	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-12	2	0	-6.5	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-14	1	6	1	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[ ]
ANC	2024-01-15	1	2	-8	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-20	1	2	-9	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-21	1	8	-12	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-01-28	2	2.5	-16	Light snow, mist	[ ]	[v]	[ ]	[v]	[ ]	[v]
ANC	2024-02-14	1	2	2	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[ ]
ANC	2024-02-20	2	5	2.5	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[ ]
ANC	2024-02-21	1	3	1	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[ ]
ANC	2024-03-02	1	2	-12	[NULL]	[ ]	[ ]	[ ]	[ ]	[ ]	[v]
ANC	2024-03-19	2	2.5	-2	Freezing (supercool	[ ]	[ ]	[ ]	[v]	[ ]	[v]

На этом шаге автоматически каждые 5 минут запускается DAG с id *dev_team_1_refresh_dm*, который производит обновление витрин.

Создание BI в DataLens
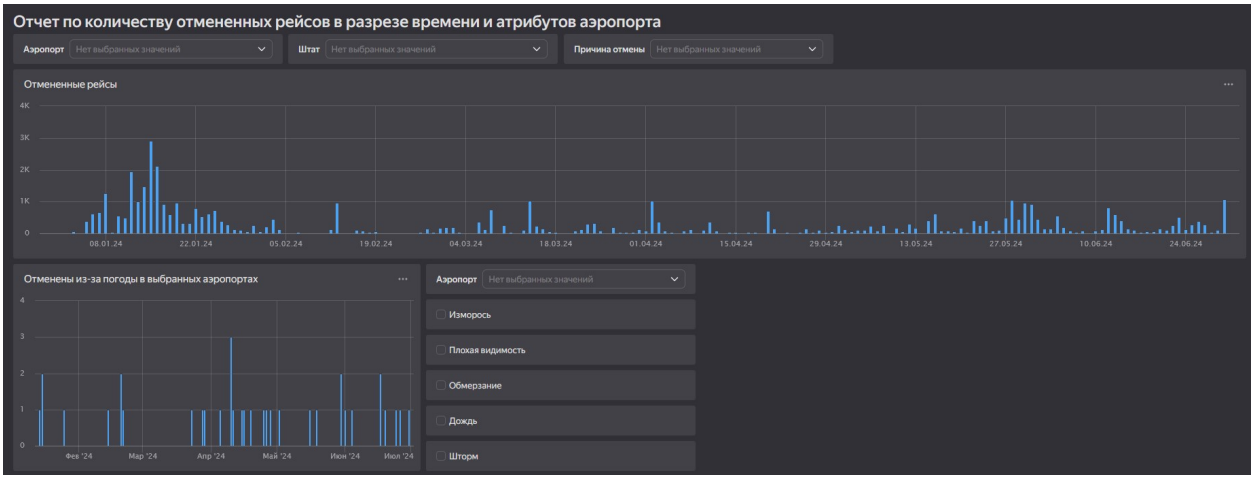
На основании этих витрин были построены дашборды в DataLens: